

# Mémoire de Master 1 - Méthodes de réduction de modèles pour la prédiction de la trainée aérodynamique

MATAR Ludovic

Mai - Septembre 2023



# Renault Group

**Encadrante :** NAFFER-CHEVASSIER Kalinja

**Etablissement :** Faculté des Sciences et Ingénierie - Sorbonne Université

**Entreprise d'accueil :** Renault Group



## **Remerciements**

J'adresse mes remerciements à l'ensemble de l'équipe Optimisation et Méthodes de Simulation Numérique de Renault au Technocentre. Cette équipe est formidable, j'ai beaucoup apprécié l'accueil chaleureux que j'ai reçu. Les échanges que j'ai pu avoir avec les membres de l'équipe et ses collaborateurs ont été riches et agréables.

Je remercie aussi Kalinja, mon encadrante, qui m'a accompagné pendant tout le déroulé du stage avec beaucoup de bienveillance.

Je voudrais aussi remercier l'équipe pédagogique du master MF2A (Mécanique des fluides, fondements & applications), notamment pour la qualité de l'enseignement dispensé au cours de l'année scolaire 2022-2023.

Matthias, Yohann et Kalinja ont été des contributeurs importants à la réalisation de mes travaux, par leurs idées et leur force de proposition. Par ailleurs, les conseils qu'ils m'ont apportés m'ont permis de confirmer mon intérêt pour la recherche en entreprise.



# Table des matières

|          |                                                                 |           |
|----------|-----------------------------------------------------------------|-----------|
| <b>1</b> | <b>Introduction</b>                                             | <b>1</b>  |
| <b>2</b> | <b>Les logiciels de simulation</b>                              | <b>3</b>  |
| <b>3</b> | <b>Calcul analytique du coefficient aérodynamique</b>           | <b>4</b>  |
| 3.1      | Méthode D'Onorato . . . . .                                     | 4         |
| 3.2      | Terme d'advection . . . . .                                     | 6         |
| 3.3      | Terme de pression statique . . . . .                            | 7         |
| 3.4      | Terme des contraintes visqueuses . . . . .                      | 7         |
| 3.5      | La formule de la trainée . . . . .                              | 7         |
| <b>4</b> | <b>Principes des méthodes de prédiction du <math>C_x</math></b> | <b>9</b>  |
| 4.1      | Le champ $S$ à prédire . . . . .                                | 9         |
| 4.2      | Morphing arrière du véhicule et paramètres de formes . . . . .  | 9         |
| 4.3      | Paramètres . . . . .                                            | 10        |
| <b>5</b> | <b>Réduction de dimension en temps</b>                          | <b>11</b> |
| 5.1      | Décomposition en valeurs singulières . . . . .                  | 11        |
| 5.2      | Réduction de la dimension par auto-encodeur . . . . .           | 16        |
| 5.3      | Les réseaux de neurones et auto-encodeurs . . . . .             | 16        |
| 5.4      | Application aux données . . . . .                               | 17        |
| <b>6</b> | <b>Méthode de prédiction QR Farfield</b>                        | <b>19</b> |
| 6.1      | Transport optimal . . . . .                                     | 19        |
| 6.2      | Objectif . . . . .                                              | 19        |
| 6.3      | Base des informations sur plan Onorato . . . . .                | 20        |
| 6.4      | Base des informations géométriques . . . . .                    | 20        |
| 6.5      | Déterminer les coefficients $a_{i,j}$ . . . . .                 | 21        |
| 6.6      | Prédiction du $SC_x$ . . . . .                                  | 22        |
| 6.7      | Application aux données . . . . .                               | 22        |
| <b>7</b> | <b>Conclusion</b>                                               | <b>24</b> |

# 1 Introduction

La réduction de modèle est un sujet très abordé dans l'industrie. Il s'agit de développer des méthodes statistiques pour prévoir le  $C_x$ , afin d'alléger les calculs. Il peut s'agir d'obtenir des algorithmes prédictifs plus simples, moins coûteux en temps et parfois plus robustes.

Le document traite des méthodes de réduction de modèle appliquées à la détermination du coefficient de trainée aérodynamique.

Objectif : Ici on s'intéresse à la trainée engendrée par les véhicules. Pour une modification de forme donnée on souhaite prévoir le coefficient de trainée aérodynamique des véhicules. La trainée est la force qui s'oppose au mouvement d'un véhicule lorsqu'il se déplace, elle est due aux frottements des particules fluides dans l'air. Le coefficient  $C_x$  est communément utilisé dans l'industrie automobile pour des prestations de performances et de consommation. Pour les prestations de tenue de route, on utilise les autres des 6 coefficients de base utilisés en aérodynamique.

Les deux méthodes de base pour déterminer le coefficient de trainée des véhicules sont les essais en soufflerie ou la CFD. Dans ce rapport on se basera exclusivement sur des résultats CFD.




FIGURE 1 – Tomographie du sillage d'un véhicule obtenue lors d'un essai en soufflerie.




FIGURE 2 – On représente en haut le champ de vitesse projeté sur l'axe  $\vec{e}_x$  et en bas la norme du gradient de pression. Ce sont les résultats d'une simulation numérique effectuée sur une Laguna. On observe par ailleurs un phénomène de décrochage de la couche limite à l'arrière du véhicule. Et là où l'écoulement est turbulent dans le sillage du véhicule et la vitesse selon  $e_x$  est faible, on observe un fort gradient de pression.

## 2 Les logiciels de simulation

En général l'approche théorique pour déterminer la traînée d'un véhicule montre vite ses limites, et il n'est pas possible de trouver une solution analytique en raison de la géométrie complexe. L'approche expérimentale une solution et permet d'aborder des problèmes très complexes. Cela consiste lors d'essais en soufflerie, à recréer un écoulement puis de mesurer certaines grandeurs caractéristiques. Seulement le coût des essais peut être très prohibitif et il faut souvent attendre que les souffleries soient disponibles.

Pour ne pas avoir à utiliser une soufflerie pour chaque véhicule en création et pour chaque modification de forme, il convient d'utiliser des outils de simulations numériques. L'utilité est grande, les outils donnent accès à des données qui ne sont disponibles sur en soufflerie comme la pression au sein même de l'écoulement par exemple. Ces logiciels sont des objets de la branche de la mécanique des fluides numérique ou computational fluid dynamics(CFD) en anglais.

Les logiciels de simulation chez Renault utilisent la méthode de Lattice-Boltzmann en discrétisant l'équation de Boltzmann sur réseau dans l'approximation BGK [5]. Cette méthode découle de la physique statistique et englobe la théorie des équations de Navier-Stokes.

En sortie des programmes on obtient des valeurs discrétisées des champs d'intérêts






FIGURE 3 – Tube de courant entourant le véhicule, un plan de sillage est représenté en gris à l'arrière. Source : THÈSE présentée par : Marion D'HONDT

comme la pression et la vitesse, pour chaque point du maillage volumique et pour chaque instant  $t$  de la simulation. Pour visualiser les résultats des logiciels de visualisation peuvent être utilisés comme par exemple Paraview. Paraview permettra aussi d'exploiter les résultats avec python.

### 3 Calcul analytique du coefficient aérodynamique

On peut déterminer la traînée à partir de la connaissance des distributions de vitesse et de pression statique dans la direction normale à l'écoulement sur un plan à l'arrière du véhicule.

#### 3.1 Méthode D'Onorato

Cette méthode permet de calculer la traînée en fonction de la pression et du champ de vitesses connus sur un plan normal à la direction de l'écoulement à l'arrière du véhicule. Se référer à l'annexe [4].

Supposons un volume fermé  $V_{fluide}$  autour du véhicule délimité par une surface fermée  $S_{fluide}$  en forme de parallépipède rectangle. Ainsi la surface délimitant le fluide est  $S = S_{fluide} \cup S_{vehicule}$ . Le volume est traversé par un écoulement stationnaire  $u_0 \mathbf{e}_x$  normal à la surface d'entrée  $S_1$  selon l'axe  $\mathbf{e}_x$  et venant de l'amont.  $S_{fluide} = S_1 \cup S_2 \cup S_L \cup S_S$ .

- $S_1$  est la surface à l'entrée du parallépipède située loin en amont et la normale sortante unitaire est  $-\mathbf{e}_x$ .
- $S_2$  est la surface à la sortie du domaine située en aval et la normale sortante unitaire est  $\mathbf{e}_x$ .
- $S_S$  est la surface au sol, la normale sortante unitaire est  $-\mathbf{e}_z$ .
- $S_L$  est l'union des surfaces latérales qu'il reste, c'est à dire "à gauche", "à droite" et "en haut". Et on suppose ces surfaces suffisamment éloignées du véhicule.

Supposons que les actions de la gravité sont négligeables devant les effets de pression, de viscosité et d'inertie et l'absence de forces volumiques sur le volume de fluide. De

plus on ne considerera pas les effets de turbulences.

On définit  $L$  la longueur de référence du véhicule,  $\rho$  et  $\mu$  sont la masse volumique et la viscosité dynamique de l'air. Dans cette situation le nombre de Reynolds est grand :  $Re = \frac{\rho u_0 L}{\mu} \gg 1$ .

Soient  $\mathbf{u}(\mathbf{x}, t) : \mathbb{R}^3 \times \mathbb{R}^+ \mapsto \mathbf{u}(\mathbf{x}, t) = (u(\mathbf{x}, t), v(\mathbf{x}, t), w(\mathbf{x}, t)) \in \mathbb{R}^3$  le champ de vitesse,  $p : (\mathbf{x}, t) \mapsto p(\mathbf{x}, t) \in \mathbb{R}$  le champ scalaire de pression statique, et  $\tau(\mathbf{x}, t) \in \mathcal{M}_{3,3}(\mathbb{R})$  la matrice du tenseur de contraintes visqueuses, fonctions de la position  $\mathbf{x} \in \mathbb{R}^3$  et du temps  $t \in \mathbb{R}^+$ . Le fluide est supposé incompressible. Les équations de Navier-Stokes s'écrivent,  $\forall (x, t) \in V_{fluide} \times \mathbb{R}^+$  :

$$\begin{cases} \nabla \cdot \mathbf{u} = 0 \\ \rho \left( \frac{\partial \mathbf{u}}{\partial t} + (\mathbf{u} \cdot \nabla) \mathbf{u} \right) = -\nabla p + \nabla \cdot \tau \end{cases}$$

On peut adimensionner les variables de position, de vitesse, de pression, de temps, et le tenseur des contraintes visqueuses :

$$\begin{cases} \mathbf{u}^* = \frac{\mathbf{u}}{u_0} \\ \tau^* = \frac{\tau}{\frac{\rho u_0 L}{\mu}} \\ t^* = \frac{t u_0}{L} \\ x^* = \frac{x}{L} \\ y^* = \frac{y}{L} \\ z^* = \frac{z}{L} \\ p^* = \frac{p}{\rho u_0^2} \end{cases}$$

En intégrant l'équation sur le volume  $V_{fluide}$  et en utilisant le théorème de Green-Ostrogradsky, on obtient le bilan de quantité de mouvement suivant  $\forall t > 0$  :

$$\iiint_{V_{fluide}} \frac{\partial \mathbf{u}^*}{\partial t^*} dV + \iint_S \mathbf{u}^* \mathbf{u}^* \cdot \mathbf{n} ds = - \iint_S p^* \mathbf{n} ds + \frac{1}{Re} \iint_S \tau^* \cdot \mathbf{n} ds$$

Le premier terme est nul car l'écoulement est stationnaire. Soit  $p_0$  la pression à l'entrée (à l'avant) du domaine fluide. Comme la surface  $S$  est fermée on a :  $\oiint_S p_0 \mathbf{n} ds = 0$ . En vertu de cette relation et de la relation de Chasles on peut alors écrire en décomposant les intégrales,  $\forall t > 0$  :

$$\begin{aligned} - \iint_{S_{fluide}} \mathbf{u}^* \mathbf{u}^* \cdot \mathbf{n} ds - \iint_{S_{fluide}} (p^* - p_0^*) \mathbf{n} ds + \frac{1}{Re} \iint_{S_{fluide}} \tau^* \cdot \mathbf{n} ds &= \iint_{S_{vehicule}} (p^* - p_0^*) \mathbf{n} ds - \\ &\quad \frac{1}{Re} \iint_{S_{vehicule}} \tau^* \cdot \mathbf{n} ds \\ \iff F_{fluide \rightarrow vehicule}^* &= -F_{vehicule \rightarrow fluide}^* \end{aligned}$$

Le membre de gauche représente la force du fluide exercée sur le véhicule. Avec les hypothèses de départ on peut simplifier ce terme.

### 3.2 Terme d'advection

- la normale à la surface  $S_1$  est  $\mathbf{e}_x$  et loin en amont du véhicule on a  $u^* = 1$  car  $u = u_0$ .
- la normale à la surface  $S_2$  étant  $-\mathbf{e}_x$  on peut écrire  $\mathbf{u}^* \mathbf{u}^* \cdot \mathbf{n} = \mathbf{u}^* \mathbf{u}^* \cdot \mathbf{e}_x = \mathbf{u}^* u^*$ .
- la normale à la surface  $S_L$  est normale à l'écoulement  $\mathbf{u}^*$  donc sur  $S_L$  l'intégrale est nulle.
- De même sur  $S_L$  l'intégrale est nulle à cause de la condition de non-glissement.

$$\begin{aligned}
 \iint_{S_{fluide}} \mathbf{u}^* \mathbf{u}^* \cdot \mathbf{n} ds &= \iint_{S_1} \mathbf{u}^* \mathbf{u}^* \cdot (-\mathbf{e}_x) ds + \iint_{S_2} \mathbf{u}^* \mathbf{u}^* \cdot \mathbf{e}_x ds + \iint_{S_L} \mathbf{u}^* \mathbf{u}^* \cdot \mathbf{n} ds + \iint_{S_S} \mathbf{u}^* \mathbf{u}^* \cdot \mathbf{n} ds \\
 &= \iint_{S_1} (-\mathbf{e}_x) ds + \iint_{S_2} \mathbf{u}^* u^* ds + 0 + 0 \\
 &= -S_1 \mathbf{e}_x + \iint_{S_2} \mathbf{u}^* u^* ds
 \end{aligned}$$

Intégrer l'équation de conservation de la masse sur le volume  $V_{fluide}$  mène à :

$$\iiint_{V_{fluide}} \nabla \cdot \rho \mathbf{u}^* dV = \iint_{S_{fluide}} \rho \mathbf{u}^* \cdot \mathbf{n} ds = 0$$

Et de même, les hypothèses mènent à des simplifications :

$$\Longleftrightarrow -\rho S_1 \cdot 1 + \iint_{S_2} \rho u^* ds = 0$$

En multipliant par  $\mathbf{e}_x$  :

$$\rho S_1 \mathbf{e}_x = \iint_{S_2} \rho u^* \mathbf{e}_x ds$$

En injectant la valeur de  $S_1 \mathbf{e}_x$  on obtient :

$$\begin{aligned}
 \Longleftrightarrow \iint_{S_{fluide}} \mathbf{u}^* \mathbf{u}^* \cdot \mathbf{n} ds &= - \iint_{S_2} u^* \mathbf{e}_x ds + \iint_{S_2} \mathbf{u}^* u^* ds \\
 \Longleftrightarrow \iint_{S_{fluide}} \mathbf{u}^* \mathbf{u}^* \cdot \mathbf{n} ds &= \iint_{S_2} (\mathbf{u} - \mathbf{e}_x) u^* ds
 \end{aligned}$$

### 3.3 Terme de pression statique

Le terme de pression se décompose de même par la relation de Chasles :

$$\iint_{S_{fluide}} (p^* - p_0^*) \mathbf{n} ds = \iint_{S_S} (p^* - p_0^*) \mathbf{n} ds + \iint_{S_1} (p^* - p_0^*) \mathbf{n} ds + \iint_{S_2} (p^* - p_0^*) \mathbf{n} ds + \iint_{S_L} (p^* - p_0^*) \mathbf{n} ds$$

- Sur la surface  $S_1$  la pression  $p^* = p_0^*$  car celle-ci est considérée loin en amont du véhicule donc l'intégrale est nulle sur  $S_1$ .
- De même les surfaces latérales  $S_L$  sont suffisamment éloignées pour considérer  $p^* = p_0^*$  donc l'intégrale est nulle sur  $S_L$ .
- Sur la surface on sait que la normale sortante à la surface est dirigée vers le bas  $\mathbf{n} = \mathbf{e}_z$ .
- Sur  $S_2$  la normale sortante est  $\mathbf{e}_x$ .

$$\iint_{S_{fluide}} (p^* - p_0^*) \mathbf{n} ds = \iint_{S_S} (p^* - p_0^*) (-\mathbf{e}_z) ds + 0 + \iint_{S_2} (p^* - p_0^*) \mathbf{e}_x ds + 0$$

### 3.4 Terme des contraintes visqueuses

$$\iint_{S_{fluide}} \tau^* \cdot \mathbf{n} ds = \iint_{S_1} \tau^* \cdot \mathbf{n} ds + \iint_{S_2} \tau^* \cdot \mathbf{n} ds + \iint_{S_L} \tau^* \cdot \mathbf{n} ds + \iint_{S_S} \tau^* \cdot \mathbf{n} ds$$

- Sur  $S_1$  la vitesse est uniforme et l'intégrale est nulle car la surface se situe loin en amont du véhicule.
- Sur  $S_2$  la normale sortante est  $\mathbf{e}_x$ .
- De même  $S_L$  la vitesse est uniforme car les surfaces sont suffisamment éloignées du véhicule et l'intégrale est nulle.
- sur  $S_S$  la normale sortante est  $-\mathbf{e}_z$ .

$$= 0 + \iint_{S_2} \tau^* \cdot \mathbf{e}_x ds + 0 - \iint_{S_S} \tau^* \cdot \mathbf{e}_z ds$$

### 3.5 La formule de la trainée

En remarquant que l'on adimensionne les surfaces avec la variable  $S_{vehicule}$ , on peut ainsi réécrire le bilan de quantité de mouvement comme suit :

$$S_{vehicule} F_{fluide \rightarrow vehicule}^* = - \iint_{S_2} (\mathbf{u} - \mathbf{e}_x) u^* ds + \frac{1}{Re} \left( \iint_{S_2} \tau^* \cdot \mathbf{e}_x ds - \iint_{S_S} \tau^* \cdot \mathbf{e}_z ds \right) + \iint_{S_S} (p^* - p_0^*) (\mathbf{e}_z) ds - \iint_{S_2} (p^* - p_0^*) \mathbf{e}_x ds$$

En projetant ce vecteur selon l'axe  $\vec{e}_x$  l'intégrale sur  $S_S$  disparaît :

$$S_{vehicule} F_{x fluide \rightarrow vehicule}^* = - \iint_{S_2} (u^* - 1) u^* ds + \iint_{S_2} (p_0^* - p^*) ds + \frac{1}{Re} \left( \iint_{S_2} \tau_{xx}^* ds - \iint_{S_S} \tau_{xz}^* ds \right)$$

En réécrivant avec les variables initiales on trouve la forme dimensionnée, notons qu'avec  $R_e$  grand le terme de viscosité peut être négligé, ce que nous ferons par la suite :

$$F_x = \rho u_0^2 S_{vehicule} F_{x fluide \rightarrow vehicule}^* = \iint_{S_2} \rho(u_0 - u)u ds + \iint_{S_2} (p_0 - p) ds + \iint_{S_2} \tau_{xx} ds - \iint_{S_S} \tau_{xz} ds$$

Remarquons qu'en écrivant l'expression avec la pression totale on obtient l'expression suivante pour la trainée :

$$F_x = \iint_{S_{aval}} (p_{i_0} - p_i) ds + \frac{\rho u_0^2}{2} \iint_{S_{aval}} \left( \frac{v^2}{u_0^2} + \frac{w^2}{u_0^2} \right) ds - \frac{\rho u_0^2}{2} \iint_{S_{aval}} \left( 1 - \frac{u}{u_0} \right)$$

Le coefficient de trainée aérodynamique est  $C_x = \frac{1}{2} F_{x fluide \rightarrow vehicule}^*$ . On peut donc écrire :

$$\frac{1}{2} \rho u_0^2 S_{vehicule} C_x = \iint_{S_2} \rho(u_0 - u)u ds + \iint_{S_2} (p_0 - p) ds + \iint_{S_2} \tau_{xx} ds - \iint_{S_S} \tau_{xz} ds \quad (1)$$

On désignera parfois le terme sous intégrale comme "terme Onorato" et on appellera cette relation "formule d'Onorato" en l'honneur d'un l'ingénieur qui a pensé à cette formulation.

## 4 Principes des méthodes de prédiction du $C_x$

L'objectif est de prédire la valeur du  $C_x$  pour chaque modification de forme donnée du véhicule, sans lancer une nouvelle simulation numérique. Elle sera déterminée à partir de grandeurs prédites sur un plan de coupe à l'arrière du véhicule, une surface appelée «plan de sillage». On s'intéressera parfois à déterminer la valeur du coefficient pour un ensemble donné d'instant.

### 4.1 Le champ $S$ à prédire

La méthode d'Onorato montre que l'on peut exprimer le coefficient de trainée en fonction du champ scalaire de pression et du champ de vitesse connus sur une surface  $\mathcal{T} \subset \mathbb{R}^2$  choisie à l'arrière du véhicule.

Pour obtenir le  $SC_x$ , on peut alors déterminer, à bonne convenance, pour tous les instants  $t \in I \subset \mathbb{R}_+$  :

- les valeurs du champ  $(p_0 - p((y, z), t)) + \rho(u_0 - u((y, z), t))u((y, z), t) \in \mathbb{R}$  sur le plan  $\mathcal{T}$  puis l'intégrer.
- ou alors séparément les valeurs du terme scalaire de pression  $(p_0 - p((y, z), t))$  et du terme de vitesse  $(u_0 - u((y, z), t))u((y, z), t)$ . Il faut ensuite intégrer la somme de ces deux termes.

Il s'agit donc de faire une ou deux prédictions sur la surface  $\mathcal{T}$  avant d'intégrer selon la relation 1. Soient :

- $\mathcal{I} \subset \mathbb{N}$  l'ensemble fini des instants  $t$  étudiés dans la simulation.
- $\mathcal{M} \subset \mathbb{N}$  l'ensemble fini des points de calcul du maillage de la surface  $\mathcal{T}$ .

On désignera  $S: \mathcal{T} \times \mathbb{R}_+ \rightarrow \mathbb{R}$  le champ scalaire que l'on souhaite prédire,  $\mathbf{S} \in \mathcal{M}_{|\mathcal{M}|, |\mathcal{I}|}(\mathbb{R})$  la discrétisation de  $S$  sur  $\mathcal{M} \times \mathcal{I}$ , et  $\hat{\mathbf{S}} \in \mathcal{M}_{|\mathcal{M}|, |\mathcal{I}|}(\mathbb{R})$  son estimateur.

### 4.2 Morphing arrière du véhicule et paramètres de formes

Dans l'industrie automobile, lorsque la conception d'un véhicule est bientôt achevée, il est fréquent que les designers apportent des modifications sur la géométrie. Les changements de formes apportés numériquement par conception assistée par ordinateur (CAO) portent le nom de "morphing".

Les morphings peuvent être vu comme des changements de positions de plusieurs points caractéristiques qui composent le maillage du véhicule. On peut ainsi ranger les informations correspondantes dans un vecteur.

Pour les études que l'on réalise on fait varier 3 paramètres de formes qui sont l'angle du pare-chocs arrière, et deux longueurs : la resserrée arrière (rearlights, soit l'espace entre les feux à l'arrière) et le "globale shape" qui décrit l'allongement du toit.




FIGURE 4 – Les trois paramètres de formes sur lesquels on travaille sont illustrés sur l’image du haut. Sur l’image du milieu, les paramètres d’étirement du toit et d’angle du pare-chocs arrière sont au minimum. Sur la figure du bas ces deux paramètres sont au maximum de leurs valeurs. On observe en effet que le toit est plus aplati pour la voiture du bas que pour la voiture du milieu, et que l’arrière est plus bas.

### 4.3 Paramètres

On fixe  $p \in \mathbb{N}^*$ , le nombre de paramètres de formes que l’on fait varier et  $\mathcal{P}$  est l’ensemble des paramètres possibles. Soient  $\mu_1, \dots, \mu_n \in \mathcal{P} \subset \mathbb{R}^p$  des vecteurs de paramètres de formes auxquels correspondent des surfaces  $\Omega_{\mu_i} \subset \mathbb{R}^3$  connexes et assez régulières. Chaque surface correspond à une variation de forme d’un même véhicule. On assure une injectivité :  $\forall \mu, \mu^* \in \mathcal{P} \subset \mathbb{R}^p, \Omega_{\mu} = \Omega_{\mu^*} \implies \mu = \mu^*$ . On note  $\mathbf{S}^{\mu_i}, i = 1, \dots, n$ , la matrice obtenue sur le champ à l’aval du véhicule, grâce aux résultats de simulations numériques. On note  $\theta = \{(\mu_i, \mathbf{S}^{\mu_i}) \in \mathcal{P} \times \mathcal{M}_{|\mathcal{M}|, |\mathcal{I}|}(\mathbb{R}), i = 1, \dots, n\}$ . L’objectif est d’établir un prédicteur  $f_{\theta}$  qui approche les valeurs du champ  $S$  pour un autre morphing  $\mu$  donné :

$$f_{\theta}: \mu \in \mathcal{P} \mapsto \hat{\mathbf{S}}^{\mu} \in \mathcal{M}_{|\mathcal{M}|, |\mathcal{I}|}(\mathbb{R})$$

La fonction  $f_{\theta}$  devra permettre de s’approcher suffisamment de la vraie valeur du  $SC_x$ . S’il on considère que le couple  $(\mu, SC_x^{\mu})$  est une variable aléatoire, et que l’on pose  $\hat{SC}_x: \mathcal{M}_{|\mathcal{M}|, |\mathcal{I}|}(\mathbb{R}) \rightarrow \mathbb{R}$  une fonction qui permet de calculer le  $SC_x$  à partir de l’estimateur  $\hat{\mathbf{S}}$ , le problème se pose de la façon suivante :

$$\min_{f \in \mathcal{F}(\mathcal{P}, \mathcal{M}_{|\mathcal{M}|, |\mathcal{I}|}(\mathbb{R}))} \mathbb{E}_{\mu} [|\hat{SC}_x(f(\mu)) - SC_x^{\mu}|]$$




FIGURE 5 – Erreur relative sur le  $SC_x$  en fonction du nombre de premières valeurs singulières retenues. En pointillés en noir sur les graphiques on observe  $k_\epsilon^\mu$  avec  $\epsilon = 0.0001$  et  $\mu \in \{126_{Ono}, 134_{Ono}, 165_{Ono}, 202_{Ono}\}$ , lorsque  $\mathbf{S}^\mu$  correspond au terme de pression, de vitesse ou au terme Onorato. Dans le tableau en bas, on lit les  $k_\epsilon^\mu$ .

## 5 Réduction de dimension en temps

En réduisant la dimension des données, on espère alléger les calculs pour prédire les champs d'intérêts. Cela permettra aussi de réduire les données trompeuses liées aux fluctuations. Il s'agit d'éliminer des informations peu représentatives du phénomène et donc d'utiliser plus efficacement les modèles de prédiction. Cela permet de pallier au phénomène du "fléau de la dimension" ("curse of dimensionality"). Par ailleurs, bien exploitées, ces méthodes permettent aussi de gagner en espace.

Ici on verra la dimension comme le nombre de pas de temps gardés dans les résultats CDF, soit le nombre de vecteurs de  $\mathbb{R}^{|\mathcal{M}|}$  qui forment la matrice  $\mathbf{S}$ . Dans un premier temps on fait le choix d'une approximation par une décomposition en valeur singulière, qui peut être vu comme une technique de POD (proper orthogonal decomposition). Cette technique est une méthode linéaire. Dans un second temps, on comparera ensuite les résultats avec ce que peut donner un autoencodeur.

### 5.1 Décomposition en valeurs singulières

Soit  $\mathbf{S}^\mu \in \mathcal{M}_{|\mathcal{M}|, |\mathcal{I}|}(\mathbb{R})$  Et supposons  $\mathbf{S}_{m,t}^\mu = (p_0 - p)_{m,t}^\mu + (\rho(u_0 - u)u)_{m,t}^\mu$ . Quitte à remplacer les valeurs de  $\mathbf{S}_{t,m}^\mu$  par ceux des termes de vitesse ou de pression. De manière générale une décomposition en valeur singulière de  $\mathbf{S}^\mu$  s'écrit :  $\mathbf{S} = \mathbf{U}\Sigma\mathbf{V}^T$ . Avec  $\mathbf{U} \in GL_{|\mathcal{M}|}(\mathbb{R})$ ,  $\mathbf{V} \in GL_{|\mathcal{I}|}(\mathbb{R})$  orthogonales et  $\Sigma = (\sigma_i \delta_{i,j})_{1 \leq i \leq |\mathcal{M}|, 1 \leq j \leq |\mathcal{I}|} \in \mathcal{M}_{|\mathcal{M}|, |\mathcal{I}|}(\mathbb{R})$  diagonale telle que les valeurs singulières  $\sigma_i$  de  $\mathbf{S}$  respectent la relation d'ordre :



$$\sigma_1 \geq \dots \geq \sigma_{|\mathcal{I}|} \geq 0.$$

Plusieurs interprétations sont possibles selon la discipline dans laquelle on travaille, dans notre cas la décomposition en valeurs singulières permet une «Analyse en composantes principales» du domaine de la statistique multivariée (c'est à dire avec plusieurs variables aléatoires). Les vecteurs  $(u_i)_{1 \leq i \leq |\mathcal{M}|}$  et  $(v_i)_{1 \leq i \leq |\mathcal{I}|}$  sont rangés dans l'ordre décroissant des valeurs des  $\sigma_i$ . L'importance de l'information rangée dans un vecteur est donc aussi grande que la valeur singulière qui lui est attribuée.

Soit  $r$  le nombre de valeurs singulières non nulles. Alors la famille  $(u_j)_{1 \leq j \leq r}$  correspondant aux colonnes de la matrice  $\mathbf{U}$  est une base de  $\text{Im } \mathbf{S}^\mu$ . Ces vecteurs correspondent donc à des valeurs prises aux instants importants du plan de sillage, et qui permettent de reconstruire l'évolution de la grandeur étudiée.

Si l'on considère notre donnée  $\mathbf{S}_{m,t}$  spatialement, les temps correspondent à des directions avec lesquelles on peut repérer les points  $m \in \mathcal{M}$  du maillage. Les premières singularités de la décomposition donnent des combinaisons linéaires de ces axes, soient les meilleurs directions sur lesquelles on peut projeter les points, c'est la famille  $(v_i)_{1 \leq i \leq r} \in (\mathbb{R}^{|\mathcal{I}|})^{\mathbb{N}}$  qui est une base de  $\text{Im}(\mathbf{S}^T)$ . Ce sont les axes qui minimisent le mieux autour d'eux la **distance quadratique moyenne** aux points.

Dans cet espace vectoriel on peut repérer un point  $m \in \mathcal{M}$  du plan Onorato par ses coordonnées qui sont les valeurs de la colonne correspondante dans la matrice :

$$\begin{aligned} (\mathbf{V}^T \mathbf{V})^{-1} \mathbf{V}^T \mathbf{S}^T &= \mathbf{V}^T (\mathbf{U} \Sigma \mathbf{V}^T)^T \\ &= (\mathbf{V}^T \mathbf{V}) \Sigma^T \mathbf{U}^T = (\mathbf{U} \Sigma)^T \in \mathcal{M}_{|\mathcal{I}|, |\mathcal{M}|}(\mathbb{R}) \end{aligned}$$

Comme  $\mathbf{V}$  est orthogonale, multiplier  $(\mathbf{U} \Sigma)^T$  par  $\mathbf{V}$  à gauche revient à appliquer une rotation pour repasser de ce repère où les axes sont orientés selon l'axe d'inertie des points, au repère initial.

Pour approcher  $\mathbf{S}$  en réduisant la dimension en temps, on peut fixer à zéro les dernières valeurs de  $\Sigma$ , puis en garder assez pour garantir un critère de reconstruction. On gardera ainsi une matrice de même taille. Le critère en question sera l'erreur relative sur le  $SC_x$ . Après avoir pris la moyenne des valeurs dans le temps sur le plan de sillage, on peut discrétiser la formule intégrale d'Onorato comme ci-dessous. Le plan de sillage est modélisé numériquement par un ensemble de  $6930 = 66 \times 105$  volumes de controles de taille  $\Delta x \Delta y$ . Pour obtenir les valeurs prises sur les volumes de contrôle, on somme les valeurs prises sur les sommets selon le théoreme du point milieu.

$$\begin{aligned} SC_x^\mu &= \frac{1}{\frac{1}{2} \rho u_0^2} \sum_{m \in \mathcal{M}} \frac{1}{|\mathcal{I}|} \sum_{t \in \mathcal{I}} \Delta x \Delta y ((p_0 - p)_{m,t}^\mu + (\rho(u_0 - u)u)_{m,t}^\mu) \\ &\quad \times (\mathbb{1}_{\{m \in \text{coins}\}} \frac{1}{4} + \mathbb{1}_{\{m \in \text{bordures}\}} \frac{1}{2} + \mathbb{1}_{\{m \in \text{interieur}\}}) \end{aligned}$$

Soit alors  $\forall k \in \llbracket 1, \text{card}(\mathcal{I}) \rrbracket$ ,  $POD(\mathbf{S}^\mu, k) \in \mathcal{M}_{|\mathcal{M}|, |\mathcal{I}|}(\mathbb{R})$  la matrice reconstruite en gardant uniquement les  $k$  premières valeurs singulières. Et soit  $SC_{x_k}^\mu$  la valeur correspondante du  $SC_x$  donnée par :

- Si  $\mathbf{S}_{m,t}^\mu$  désigne la somme des termes de pression et de vitesse alors :

$$SC_{x_k}^\mu = \frac{1}{\frac{1}{2}\rho u_0^2} \sum_{m \in \mathcal{M}} \frac{1}{|\mathcal{I}|} \sum_{t \in \mathcal{I}} \Delta x \Delta y POD(\mathbf{S}^\mu, k)_{m,t} (\mathbb{1}_{\{m \in \text{coins}\}} \frac{1}{4} + \mathbb{1}_{\{m \in \text{bordures}\}} \frac{1}{2} + \mathbb{1}_{\{m \in \text{interieur}\}}), \forall k \in \llbracket 1, \text{card}(\mathcal{I}) \rrbracket$$

- Si  $\mathbf{S}_{m,t}^\mu$  désigne le terme de pression, alors :

$$SC_{x_k}^\mu = \frac{1}{\frac{1}{2}\rho u_0^2} \sum_{m \in \mathcal{M}} \frac{1}{|\mathcal{I}|} \sum_{t \in \mathcal{I}} \Delta x \Delta y (POD(\mathbf{S}^\mu, k)_{m,t} + \rho(u_0 - u)u) \times (\mathbb{1}_{\{m \in \text{coins}\}} \frac{1}{4} + \mathbb{1}_{\{m \in \text{bordures}\}} \frac{1}{2} + \mathbb{1}_{\{m \in \text{interieur}\}}), \forall k \in \llbracket 1, \text{card}(\mathcal{I}) \rrbracket$$

- Si  $\mathbf{S}_{m,t}^\mu$  désigne le terme de vitesse, alors :

$$SC_{x_k}^\mu = \frac{1}{\frac{1}{2}\rho u_0^2} \sum_{m \in \mathcal{M}} \frac{1}{|\mathcal{I}|} \sum_{t \in \mathcal{I}} \Delta x \Delta y ((p_0 - p)_{m,t}^\mu + POD(\mathbf{S}^\mu, k)_{m,t}) \times (\mathbb{1}_{\{m \in \text{coins}\}} \frac{1}{4} + \mathbb{1}_{\{m \in \text{bordures}\}} \frac{1}{2} + \mathbb{1}_{\{m \in \text{interieur}\}}), \forall k \in \llbracket 1, \text{card}(\mathcal{I}) \rrbracket$$

On s'intéresse au comportement de l'erreur relative sur le  $SC_x$  en fonction du nombre de valeurs singulières sélectionnées. Soit  $1 \gg \epsilon > 0$  petit. Pour chaque configuration  $\mu$ , on cherchera numériquement le nombre  $k_\epsilon^\mu$  tel que :

$$|\frac{SC_x^\mu - SC_{x_k}^\mu}{SC_x^\mu}| \leq \epsilon, \forall \text{card}(\mathcal{I}) \geq k \geq k_\epsilon^\mu$$

On s'intéresse aussi à l'erreur commise sur la reconstruction des modes, on regarde donc les quantités ci-dessous, qui ont les propriétés d'une distance matricielle :

$$\forall k \in \llbracket 1, \text{card}(\mathcal{I}) \rrbracket, \forall \mu \in \mathcal{P}, \max_{L_2}(\mathbf{S}^\mu, POD(\mathbf{S}^\mu, k)) = \max_{t \in \mathcal{I}} \frac{\|(\mathbf{S}^\mu - POD(\mathbf{S}^\mu, k))e_t\|_2}{\|\mathbf{S}^\mu e_t\|_2}$$

$$\forall k \in \llbracket 1, \text{card}(\mathcal{I}) \rrbracket, \forall \mu \in \mathcal{P}, \text{mean}_{L_2}(\mathbf{S}^\mu, POD(\mathbf{S}^\mu, k)) = \frac{1}{|\mathcal{I}|} \sum_{t \in \mathcal{I}} \frac{\|(\mathbf{S}^\mu - POD(\mathbf{S}^\mu, k))e_t\|_2}{\|\mathbf{S}^\mu e_t\|_2}$$

Sur la figure 5, on observe comment évolue l'erreur relative en fonction du nombre de valeurs singulières retenues, pour la pression, la vitesse et le terme Onorato, pour simulations numériques  $\mu \in \{126_{\text{Ono}}, 134_{\text{Ono}}, 165_{\text{Ono}}, 202_{\text{Ono}}\}$ . On constate qu'il ne suffit que de peu de valeurs singulières pour obtenir une erreur relative inférieure à 0.01%. Pour chaque terme (vitesse, pression, Onorato), les valeurs de la dimension  $k_\epsilon^\mu$  sont dans




FIGURE 6 – Erreur  $max_{L2}$ ,  $k_\epsilon^\mu$  pour  $\epsilon = 0.0002$   
 $\mu \in \{126_{Ono}, 134_{Ono}, 165_{Ono}, 202_{Ono}\}$ .




FIGURE 7 – Erreur  $mean_{L2}$ ,  $k_\epsilon^\mu$  pour  $\epsilon = 0.0002$   
 $\mu \in \{126_{Ono}, 134_{Ono}, 165_{Ono}, 202_{Ono}\}$ .

le même ordre de grandeurs pour les différents calculs  $\mu$ , sauf, pour le calcul  $126_{Ono}$  où la courbe d'erreur décroît très vite. Les résultats obtenus sur les plans de sillage sont presque aléatoires ce qui implique l'allure bruitée des courbes.

Sur les figures 6 et 7, il est intéressant de remarquer que pour les distances énoncées plus haut, et pour chaque grandeur considérée, les allures des courbes d'erreur en fonction du nombre de valeurs singulières retenues sont identiques pour les différents calculs  $\mu$ . De plus entre les grandeurs  $max_{L2}$  et  $mean_{L2}$  les allures sont très similaires. En effet en dimension finie toutes les normes sont équivalentes.

Avec seulement, la première valeur singulière sélectionnée, l'erreur relative sur le  $SC_x$  varie entre 0.1% et 0.2%. Par ailleurs on observe sur la figure 9 le plan de sillage reconstruit. Repérons de nouveau les points  $m \in \mathcal{M}$  dans un espace où les axes sont les  $(v_i)_{1 \leq i \leq r} \in (\mathbb{R}^{|I|})^{\mathbb{N}}$  (les mélanges des temps les plus caractéristiques). Le fait que le nuage de points de  $\mathcal{M}$  soit centré autour du premier vecteur singulier - la distance quadratique moyenne entre les points et l'axe  $v_1$  étant minimale - assure que la quantité  $\mathbf{S}^\mu - POD(\mathbf{S}^\mu, 1)$  contienne des informations relatives à la variance de  $t \mapsto S(m, t)$ . C'est à dire ici de l'écart quadratique à la moyenne temporelle de la quantité pour chaque point. De plus le  $SC_x$  se calcule à partir des valeurs **moyennées** dans le temps du champ Onorato sur le plan de sillage. Il est donc en effet attendu qu'à partir de la première valeur singulière on puisse prédire une valeur du  $SC_x$  du bon ordre de grandeur. Les observations de la figure 8 vont dans ce sens.

Une approche pour retenir moins de valeurs est de réaliser le même travail pour la transformée de Fourier discrète de la matrice  $\mathbf{S}$ . Il s'agit de réaliser pour chaque  $m \in \mathcal{M}$  la transformée de  $f_m: t \in \llbracket 0, card(\mathcal{I}) \rrbracket \mapsto \mathbf{S}_{m,t}^\mu \in \mathbb{R}$ . On obtient donc une matrice dont les colonnes correspondent à des fréquences et les lignes correspondent aux points du plan de sillage. Mes travaux ont montré que dans ce cas que l'erreur relative sur le  $SC_x$  mène au même nombre de valeurs singulières retenues.




FIGURE 8 – On représente l'écart type de  $t \mapsto \mathbf{S}^\mu(m, t)$  pour  $\mu \in \{126_{Ono}, 134_{Ono}, 163_{Ono}\}$ .  $\mathbf{S}^\mu$  désigne le terme de pression, de vitesse ou Onorato. On remarque que pour chaque terme, les champs qui représentent les erreurs en valeurs absolues sur la figure 6, apparaissent comme proportionnels aux champs qui représentent l'écart-type.




FIGURE 9 – En haut à gauche on visualise  $\mathbf{S}_{m,t}^\mu = (p_0 - p)_{m,t}^\mu + (\rho(u_0 - u)u)_{m,t}^\mu$ . En bas à gauche on visualise  $POD(\mathbf{S}^\mu, k = 1)$ , c'est donc la reconstruction du champ avec uniquement la première valeur singulière. En haut à droite on visualise la différence en valeur absolue  $|POD(\mathbf{S}^\mu, k)_{m,t} - \mathbf{S}_{m,t}^\mu|$ . En bas à droite on visualise une quantité analogue à une erreur relative pour tous les points  $(m, t)$ . Ce choix a été fait pour obtenir une quantité bornée. Les zones où les valeurs sont élevées correspondent à un régime d'écoulement turbulent. Le phénomène étant quasi aléatoire, certaines fluctuations ne peuvent être "captées" par les premières valeurs singulières. Les turbulences sont provoquées par le décrochage de la couche limite à l'approche de l'arrière du véhicule. C'est la trainée de forme.

## 5.2 Réduction de la dimension par auto-encodeur

Les architectures de réseaux de neurones de type autoencodeur permettent également de réduire le volume de certains signaux. Ces derniers peuvent permettre de résoudre des problèmes aux propriétés non linéaires. On se propose donc cette approche.

## 5.3 Les réseaux de neurones et auto-encodeurs

Soit un ensemble de données correspondant à des variables indépendantes et identiquement distribuées selon une loi inconnue :  $\{(X_1, Y_1), \dots, (X_d, Y_d)\} \stackrel{\text{iid}}{\sim} P_{(X,Y)}$ .  $X$  est à valeurs dans  $\mathcal{X} \subset \mathbb{R}^n$  et  $Y$  est à valeurs dans  $\mathcal{Y} \subset \mathbb{R}^p$ . Pour chaque indice  $i$ ,  $X_i$  désigne un objet et  $Y_i$  désigne un "label" ou un réel associé. On parle alors d'un problème de classification ou de régression.

Soit  $\Theta$  un ensemble de paramètres. Un prédicteur est alors une fonction mesurable  $f_{\theta \in \Theta} : \mathcal{X} \rightarrow \mathcal{Y}$  telle que  $f_{\theta \in \Theta}(X)$  vise à approcher  $Y$ . On souhaitera alors minimiser sur les données une erreur de généralisation qui correspond à l'espérance d'une fonction de perte  $\mathcal{L} : \mathcal{Y} \times \mathcal{Y} \rightarrow \mathbb{R}^+$  soit  $\mathbb{E}[\mathcal{L}(Y, f_{\theta}(X))]$ . Le choix de la fonction de perte dépend des situations.

Pour un réseaux de neurones  $f_{\theta}$ ,  $\theta$  désigne une collection de matrices calculée lors de la phase "d'apprentissage" : C'est la minimisation de l'erreur de généralisation par un algorithme de descente de gradient.

Un réseau à  $L$  couches cachées peut généralement se définir comme suit :

$$\begin{cases} h_0 = x \\ h_1 = \sigma_1(\mathbf{W}_1^T h_0 + b_1) \\ \vdots \\ h_L = \sigma_L(\mathbf{W}_L^T h_{L-1} + b_L) \\ f_{\theta}(x) = h_L = \tilde{y}, \quad \forall x \in \mathcal{X} \end{cases}$$

Et  $\theta = \{\mathbf{W}_i^T, b_i, i = 1, \dots, L\}$ . Les  $h_i$  sont appelés couches (leur "taille" correspond à leur longueur en tant que vecteur, soit au nombre de lignes de la matrice  $\mathbf{W}_i$ ) et les  $\sigma_i$  appelées fonction d'activation.  $h_0$  est la couche d'entrée et  $h_L$  est la couche de sortie. Ce sont des fonctions continues dérivables et dans la majorité des cas non linéaires.

Un auto-encodeur est une fonction dont le but est de reconstruire l'information en entrée, dans ce cas  $f_{\theta}$  est une fonction de  $\mathcal{X}$  à valeurs dans  $\mathcal{X}$ .




FIGURE 10 – Ici  $\mu = 126_{Ono}$ ,  $\mathbf{S}_{m,t}^\mu = (p_0 - p)_{m,t}^\mu + (\rho(u_0 - u)u)_{m,t}^\mu$ . L'architecture entraînée est  $f_\theta(x)$  définie dans l'équation 2. À gauche l'erreur relative pour le  $SC_x$  en fonction du nombre du nombre d'unités sur la couche cachée est représentée. En rouge sont les points avec une erreur plus petite que 0.1%. À droite on représente la perte moyenne quadratique calculée sur l'ensemble de test. Pour chaque réseau, 80 epochs ont été réalisées, pour s'assurer que la perte converge bien. Un pas d'apprentissage de  $lr = 10^{-1}$  et un moment  $m = 0.9$  ont été choisis pour une descente de gradient stochastique avec des batch de taille 100.

#### 5.4 Application aux données

Dans la matrice  $\mathbf{S}$  on considère les données qui correspondent aux points  $m \in \mathcal{M}$  c'est à dire les lignes. ( $\mathcal{X} = \{\mathbf{S}e_m \in \mathbb{R}^{|\mathcal{I}|} | m \in \mathcal{M}\}$ ) On suppose que ce sont des vecteurs aléatoires réels. On a donc  $\text{card}(\mathcal{M})$  individus. Notre objectif est donc de pouvoir reconstruire les champs point par point.

On sépare les données de la matrice  $\mathbf{S}$  en deux parties. On a 801 pas de temps et 6930 points sur le plan de sillage. On sélectionne aléatoirement 80% des individus (points) du plan de sillage pour l'ensemble d'entraînement et on garde 20% pour l'ensemble de test.

L'architecture que l'on choisit dans un premier temps est la suivante. Elle est dépourvue de fonction d'activation, et possède  $d \in \mathbb{N}^*$  unités sur son unique couche cachée. La partie «encodeur» est  $h_1$  et la partie «décodeur» est  $h_1 \mapsto h_2$ . Bien entendu la taille de la couche de sortie est la même que la taille que la couche d'entrée :

$$\begin{cases} h_0 = x \\ h_1 = \mathbf{W}_1^T h_0 + b_1, & \mathbf{W}_1 : |\mathcal{I}| \times d \\ h_2 = \mathbf{W}_2^T h_1 + b_2, & \mathbf{W}_2 : d \times |\mathcal{I}| \\ f_\theta(x) = h_2 = \tilde{x}, & \forall x \in \mathcal{X} \subset \mathbb{R}^{|\mathcal{I}|} \end{cases} \quad (2)$$

Sur la figure 10 on montre l'erreur relative obtenue sur le  $C_x$ . L'erreur minimale obtenue est  $\epsilon = 0.004069\%$ , pour  $d = 9$  unités sur la couche cachée centrale. C'est la dimension de l'espace latent dans lequel sont représentés les points  $m \in \mathcal{M}$ . L'information de la matrice  $\mathbf{S}$  peut donc être approximée par  $m$  vecteurs de taille  $d$ . Ainsi dans un processus de prédiction du  $SC_x$  il suffira de prédire ces vecteurs avant d'utiliser la partie décodeur du réseau pour obtenir une approximation  $\hat{\mathbf{S}}$  de  $\mathbf{S}$ .




FIGURE 11 – En haut à gauche on visualise  $\mathbf{S}_{m,t}^\mu = (p_0 - p)_{m,t}^\mu + (\rho(u_0 - u)u)_{m,t}^\mu$ . En bas à gauche on visualise la reconstruction pour l'architecture présentée à l'équation 2, c'est donc la reconstruction avec 9 unités sur la couche cachée. L'erreur obtenue étant  $\epsilon = 0.004069\%$  il convient d'utiliser une matrice de taille  $|\mathcal{M}| \times |\mathcal{I}| = 6930 \times 9$  au lieu d'une matrice de taille  $6930 \times 801$ . En haut à droite on visualise la différence en valeur absolue. En bas à droite on visualise une quantité analogue à une erreur relative pour tous les points  $(m, t)$ .

D'autres approches plus complexes sont possibles pour peut-être plus de performance, par exemple en rajoutant des fonctions d'activation  $\sigma$  ou alors comme augmenter la profondeur de l'architecture en ajoutant plus de couches cachées. Des approches avec d'autres types d'architectures pourraient également être envisageables. On peut par exemple utiliser des auto encodeurs à base de réseaux convolutifs. Ainsi les individus à "reconstruire" sont les valeurs des champs pris en "2D", comme des images. Et il y a autant d'individus que de pas de temps  $|\mathcal{I}|$ . Cependant l'inconvénient majeur de cette approche est qu'elle nécessite beaucoup de données. On est dans le cas  $|\mathcal{M}| \gg |\mathcal{I}|$  et donc dans ce cas de figure, il y a beaucoup plus de points sur les champs à prédire que d'individus dans la base d'apprentissage. Mes tentatives ont alors montré que cette approche ne fonctionne pas aussi bien que l'on veut.

## 6 Méthode de prédiction QR Farfield

Dans la méthode QR-Farfield, on exploite les résultats de plusieurs simulations CFD. Supposons que l'on a  $K \in \mathbb{N}^*$  configurations géométriques  $\mu_k$  pour un véhicule et les résultats des simulations numériques correspondantes, en particulier les valeurs des champs de vitesse et scalaire de pression sur une surface à l'arrière d'un véhicule. La distance entre la surface et l'arrière du véhicule est fixée. On peut donc voir ces  $K$  ressources disponibles comme un ensemble "d'entraînement" comme en Machine Learning. La méthode de prédiction QR Farfield agrège des données relatives aux valeurs des champs obtenus pour les  $K$  configurations et des données relatives aux différentes géométries. La méthode porte son nom de la décomposition QR des matrices.

### 6.1 Transport optimal

On discrétise les surfaces  $(\Omega_{\mu_k})_{1 \leq k \leq K}$  pour obtenir les ensembles de centroïdes  $\Omega_{\mu_i}^d = \{c_{\mu_i}^j \in \mathbb{R}^3, 1 \leq j \leq \#\Omega_{\mu_i}^d\}$ . Ces discrétisations peuvent avoir des cardinaux différents. On se donne une configurations de référence  $\Omega_{\mu_{ref}}$  et on considère que toutes les autres dont on dispose sont des déformations de celle-ci. On supposera que  $Card(\Omega_{\mu_{ref}}^d) > K$ . On établie ensuite numériquement le plan de transport optimal  $\pi_{\Omega_{\mu_k}^d \rightarrow \Omega_{\mu_{ref}}^d}$  entre chaque  $\Omega_{\mu_k}^d$  et  $\Omega_{\mu_{ref}}^d$  défini par un problème d'optimisation sous contraintes :

$$\pi_{\Omega_{\mu_k}^d \rightarrow \Omega_{\mu_{ref}}^d} = argmin_{\substack{[m_{i,j}]_{i,j}, \\ \sum_i m_{i,j}=1, 1 \leq i \leq Card(\Omega_{\mu_k}^d), \\ \sum_j m_{i,j}=1, 1 \leq j \leq Card(\Omega_{\mu_{ref}}^d), \\ m_{i,j} > 0}} \sum m_{i,j} \|c_{\mu_k}^i - c_{\mu_{ref}}^j\|_2^2$$

C'est une stratégie de déplacement où  $m_{i,j}$  représente comment transporter les centroïdes de  $\Omega_{\mu_k}^d$  à l'emplacement de ceux de  $\Omega_{\mu_i}^d$  en minimisant le coût ici choisi.

### 6.2 Objectif

On cherche ici à évaluer le coefficient  $SC_x(t)$  moyenné sur le temps.

Soit  $S^\mu: ((y, z), t) \in \mathcal{T} \times \mathbb{R}^+ \mapsto (p_0 - p((y, z), t)^\mu) + \rho(u_0 - u^\mu((y, z), t))u^\mu((y, z), t) \in \mathbb{R}$ , la quantité sous l'intégrale dans la formule d'Onorato.

On veut évaluer  $\bar{S}^\mu: (y, z) \in \mathcal{T} \mapsto (p_0 - \bar{p}(y, z)^\mu) + \rho(u_0 - \bar{u}^\mu(y, z))\bar{u}^\mu(y, z) \in \mathbb{R}$ . On pourra ainsi approcher le coefficient de trainée numériquement :

$$\frac{1}{2}\rho u_0^2 \overline{S_{vehicule} C_x} = \iint_{\mathcal{T}} \rho(u_0 - \bar{u})\bar{u} ds + \iint_{\mathcal{T}} (p_0 - \bar{p}) ds$$



On suppose que l'on peut écrire sous la forme linéaire :

$$\forall \mu \in \mathcal{P}, \forall (y, z) \in \mathcal{T} \subset \mathbb{R}^2, \bar{S}^\mu(y, z) = \bar{S}^{\mu_{ref}}(y, z) + \sum_{\substack{1 \leq i \leq K, \\ 1 \leq j \leq K}} a_{i,j} \Phi_i(y, z) \nu_j^\mu$$

où

$${}^t[\Phi_1(y, z) \ \cdots \ \Phi_K(y, z)] \in \mathbb{R}^K$$

$$\nu^\mu = {}^t[\nu_1^\mu \ \cdots \ \nu_K^\mu] \in \mathbb{R}^K$$

$$\mathbf{A} = [a_{i,j}]_{i,j} \in \mathcal{M}_{K,K}(\mathbb{R})$$

Les  $\Phi_k(y, z)$  renseignent sur les valeurs de  $\bar{S}^{\mu_k}(y, z) - \bar{S}^{\mu_{ref}}(y, z)$  prises pour les autres calculs.  $\nu(\mu)$  correspond à un descripteur agrégé de la forme  $\Omega_{\mu_k}$  calculé à l'aide des plans de transports  $\pi_{\Omega_{\mu_k}^d \rightarrow \Omega_{\mu_{ref}}^d}$ .

Il faut continuer avec la discrétisation  $\mathcal{M}$  de  $\mathcal{T}$  pour poursuivre le raisonnement. On suppose la relation suivante :

$$\begin{aligned} \bar{\mathbf{S}}^\mu &= \bar{\mathbf{S}}^{\mu_{ref}} + \sum_{\substack{1 \leq i \leq K, \\ 1 \leq j \leq K}} a_{i,j} \Phi_i \nu_j(\mu) \in \mathbb{R}^{|\mathcal{M}|}, \forall \mu \in \mathcal{P} \\ \iff \bar{\mathbf{S}}^\mu - \bar{\mathbf{S}}^{\mu_{ref}} &= \Phi \mathbf{A} \nu^\mu \end{aligned}$$

où

$$\Phi = [\Phi_1 \ \cdots \ \Phi_K] \in \mathcal{M}_{|\mathcal{M}|,K}(\mathbb{R})$$

$$\nu^\mu = {}^t[\nu_1^\mu \ \cdots \ \nu_K^\mu] \in \mathbb{R}^K$$

$$\mathbf{A} = [a_{i,j}]_{i,j} \in \mathcal{M}_{K,K}(\mathbb{R})$$

$$\bar{\mathbf{S}}^\mu = p_0 - \bar{p}^\mu + \rho(u_0 - \bar{u}^\mu) \bar{u}^\mu, \forall \mu \in \mathcal{P}$$

### 6.3 Base des informations sur plan Onorato

Soit  $\mathbf{X} = [(\bar{\mathbf{S}}^{\mu_1} - \bar{\mathbf{S}}^{\mu_{ref}}) \ \cdots \ (\bar{\mathbf{S}}^{\mu_K} - \bar{\mathbf{S}}^{\mu_{ref}})] \in \mathcal{M}_{|\mathcal{M}|,K}(\mathbb{R})$ . La décomposition  $QR$  de la matrice  $\mathbf{X}$  s'écrit :

$$\mathbf{X} = \Phi R_1$$

Avec  $\Phi \in \mathcal{M}_{|\mathcal{M}|,K}(\mathbb{R})$  telle que la famille des colonnes soit orthonormée et  $R_1 \in \mathcal{M}_{K,K}(\mathbb{R})$  triangulaire supérieure. L'ensemble des  $K$  ressources qui correspondent à l'ensemble "d'entraînement" sont rangées dans  $\mathbf{X}$ .

### 6.4 Base des informations géométriques

On va faire une autre décomposition  $QR$  à partir des informations géométriques. Définissons quelques métriques qui évaluent la distance entre les différentes configurations  $\mu_k$  et  $\mu_{ref}$  :

- Commençons par le coût qui minimise le transport optimal, c'est une sorte de mesure du déplacement des centroïdes.

$$d_k^j = \sum_{i=1}^{Card(\Omega_{\mu_k}^d)} m_{k,i,j} \|c_{\mu_k}^i - c_{\mu_{ref}}^j\|_2^2, \forall 1 \leq j \leq \#\Omega_{\mu_{ref}}, \forall 1 \leq k \leq K$$

où  $\pi_{\Omega_{\mu_k}^d \rightarrow \Omega_{\mu_{ref}}^d} = [m_{k,i,j}]_{i,j}$ .

— On essaye plusieurs formules :

| $d_k^j$                                                                                                                                     | norme                   |
|---------------------------------------------------------------------------------------------------------------------------------------------|-------------------------|
| $\sum_{i=1}^{Card(\Omega_{\mu_k}^d)} m_{i,j} \ c_{\mu_k}^i - c_{\mu_{ref}}^j\ _2^2 \text{sign}((c_{\mu_k}^i - c_{\mu_{ref}}^j, n_{ref}^j))$ | «df2»                   |
| $\sum_{i=1}^{Card(\Omega_{\mu_k}^d)} m_{i,j} (c_{\mu_k}^i - c_{\mu_{ref}}^j, n_{ref}^j)$                                                    | «ps norm»               |
| $\sum_{i=1}^{Card(\Omega_{\mu_k}^d)} m_{i,j} \ln \frac{\ c_{\mu_k}^i\ }{\ c_{\mu_{ref}}^j\ }$                                               | «kl» (Kullback-Leibler) |
| $\sum_{i=1}^{Card(\Omega_{\mu_k}^d)} m_{i,j} \ c_{\mu_k}^i - c_{\mu_{ref}}^j\ _1$                                                           | «l1»                    |

Les vecteurs  $d_k = {}^t \begin{bmatrix} d_k^j & \dots & d_k^{Card(\Omega_{\mu_{ref}}^d)} \end{bmatrix} \in \mathbb{R}^{Card(\Omega_{\mu_{ref}}^d)}$  sont rangés dans la matrice  $D$ :

$$\mathbf{D} = [d_1 \ \dots \ d_K] \in \mathcal{M}_{Card(\Omega_{\mu_{ref}}^d), K}(\mathbb{R})$$

Le coefficient  $\mathbf{D}_{i,j} = d_i^j$  représente le coût du transport des centroïdes de  $\Omega_{\mu_j}$  au point  $c_{\mu_{ref}}^j$  de  $\Omega_{\mu_{ref}}$ . La décomposition  $QR$  de  $\mathbf{D}$  s'écrit :

$$\mathbf{D} = \mathbf{Q}\mathbf{R}_2$$

Avec  $\mathbf{Q} \in \mathcal{M}_{Card(\Omega_{\mu_{ref}}^d), K}(\mathbb{R})$  telle que la famille des colonnes soit orthonormée et  $\mathbf{R}_2 \in \mathcal{M}_{K,K}(\mathbb{R})$  triangulaire supérieure. Et soit  $\nu^{\mu_k}$  défini comme :

$$\nu^{\mu_k} = {}^t \mathbf{Q} d_k \in \mathbb{R}^K, \forall 1 \leq k \leq K$$

Ainsi défini,  $\mathbf{R}_2 = [\nu^{\mu_1} \ \dots \ \nu^{\mu_K}]$  car  ${}^t \mathbf{Q}\mathbf{Q} = \mathbf{I}_{K,K}$  (attention  $\mathbf{Q}^t \mathbf{Q} \neq \mathbf{I}_{Card(\Omega_{\mu_{ref}}^d), Card(\Omega_{\mu_{ref}}^d)}$ ).

### 6.5 Déterminer les coefficients $a_{i,j}$

On souhaite avoir  $\mathbf{A} \in \mathcal{M}_{K,K}(\mathbb{R})$  telle que  $\overline{\mathbf{S}^\mu} - \overline{\mathbf{S}^{\mu_{ref}}} = \Phi \mathbf{A} \nu^\mu$ . Mais pour agréger les données des configurations  $\mu_1 \dots \mu_K$  on recherche  $\mathbf{A}$  sous la forme :

$$\mathbf{X} = \Phi \mathbf{A} \mathbf{R}_2$$

En supposant que  $\mathbf{R}_2$  est inversible on a alors :

$$\begin{aligned} \mathbf{A} &= ({}^t \Phi \Phi)^{-1} {}^t \Phi \mathbf{X} \mathbf{R}_2^{-1} \\ \iff \mathbf{A} &= {}^t \Phi \mathbf{X} \mathbf{R}_2^{-1}, \text{ car } {}^t \Phi \Phi = \mathbf{I}_{K,K} \end{aligned}$$




FIGURE 12 – Représentation dans  $\mathbb{R}^3$  des vecteurs de paramètres de formes  $\mu$ . On observe que la distribution est presque aléatoire.

## 6.6 Prédiction du $SC_x$

Une fois les matrices  $\mathbf{A}$  et  $\Phi$  obtenues, pour prédire le champ sous la forme  $\overline{\mathbf{S}}^\mu = \overline{\mathbf{S}}^{\mu_{ref}} + \Phi \mathbf{A} \nu^\mu \in \mathbb{R}^{|\mathcal{M}|}$ ,  $\forall \mu \in \mathcal{P}$ , il convient de faire la prédiction cinq étapes :

- Calculer le plan de transport optimal entre  $\Omega_\mu^d$  et  $\Omega_{\mu_{ref}}^d$
- Calculer  $d_\mu = {}^t[d^j \dots d^{Card(\Omega_{\mu_{ref}}^d)}] \in \mathbb{R}^{Card(\Omega_{\mu_{ref}}^d)}$  de la même manière que pour l'ensemble les configurations  $\mu_1 \dots \mu_K$  avec les informations des plans de transport.
- Calculer  $\nu^\mu = \mathbf{Q}^\top \cdot d_\mu \in \mathbb{R}^K$
- Calculer  $\overline{\mathbf{S}}^\mu = \overline{\mathbf{S}}^{\mu_{ref}} + \Phi \mathbf{A} \nu^\mu = \overline{\mathbf{S}}^{\mu_{ref}} + \Phi^t \Phi \mathbf{X} \mathbf{R}_2^{-1} \nu^\mu \in \mathbb{R}^{|\mathcal{M}|}$
- Calculer  $\overline{SC}_x^\mu = \frac{1}{2\rho u_0^2} \sum_{m \in \mathcal{M}} \Delta x \Delta y \overline{\mathbf{S}}_m^\mu (\mathbf{1}_{\{m \in coins\}} \frac{1}{4} + \mathbf{1}_{\{m \in bordures\}} \frac{1}{2} + \mathbf{1}_{\{m \in interieur\}})$

## 6.7 Application aux données

On dispose de  $K = 30$  morphings  $(\Omega_{\mu_k})_{1 \leq k \leq K}$  avec les résultats des simulations associées  $\overline{\mathbf{S}}^{\mu_k}$ . Les paramètres choisis pour les morphings peuvent être représentés sur la figure 12. Comme  $K$  n'est pas très élevé, plutôt que de séparer les ressources en deux ensembles, d'entraînement, et de test, on utilise une approche de la validation croisée. Il s'agit dans un premier temps de séparer l'ensemble en une partition à  $T \in \mathbb{N}$  éléments :  $\mathcal{S} = \{(S_k, \Omega_{\mu_k}^d) | 1 \leq k \leq K\} = \cup_{i=1}^T \mathcal{S}_i, \forall 1 \leq i, j \leq T, \mathcal{S}_i \cap \mathcal{S}_j = \emptyset$ . Les  $\mathcal{S}_i$  sont de même taille ou presque, et la répartition est aléatoire. On sélectionne un des  $T$  échantillons pour le traiter comme un ensemble de calculs d'entraînement avec lequel on formera la matrice  $\mathbf{X}$ . On garde les  $T - 1$  parties de  $\mathcal{S}$  pour évaluer l'erreur relative sur le  $SC_x$ . On aura donc  $T - 1$  erreurs moyennes  $\epsilon_i$ , et on pourra calculer la "moyenne des moyennes" pour obtenir une première évaluation. On répète ensuite le procédé pour chaque partie  $\mathcal{S}_i$  toujours en évaluant l'erreur avec les  $T - 1$  autres parties restantes. Il y aura donc au total  $T$  évaluations pour la méthode.

On fera attention au fait qu'ici, si  $T$  est élevé, il y a de nombreuses ressources pour




FIGURE 13 – On montre l’erreur moyenne sur le  $SC_x$ , obtenue par validation croisée, pour différentes versions de  $d$ , pour les 30 ressources disponibles. Ici  $T \in \{3, 4, 5\}$  'kl' est la formule de  $d$  qui performe le mieux et permet une erreur relative inférieure à 1%

évaluer le modèle, et donc moins de variance pour les erreurs, mais un biais plus important car le modèle à moins d’informations pour être entraîné. Au contraire si  $T$  est faible, il y a plus de ressources pour former le modèle donc le biais est diminué, et l’erreur plus petite, mais la variance est plus élevée (donc le modèle est moins fiable) car il y en a moins pour évaluer le modèle. C’est le dilemme biais-variance. Il faut donc choisir une bonne valeur de  $T$ . On essaye donc des valeurs différentes de  $T$  avec les différentes mesures de déplacement  $d$  énoncées plus haut.

Les techniques d’évaluation présentées dans les figures permettent d’affirmer que c’est avec la distance «ps-norm» que la méthode QR fonctionne le mieux.

$$d = \sum_{i=1}^{Card(\Omega_{\mu_k})} m_{i,j}^j (c_{\mu_k}^i - c_{\mu_{ref}}^j, n_{ref}^j)$$

Les résultats sur la figure 13 montrent aussi grossièrement que la performance augmente avec le nombre de ressources pour former le modèle. Cependant il faudra porter attention aux valeurs de la variance pour retenir une valeur raisonnable de l’erreur relative. Par ailleurs, il peut être intéressant de déterminer quelle est en moyenne l’erreur maximale sur l’ensemble de validation. C’est notamment ce qui est fait avec la technique évoquée sur la 14.




FIGURE 14 – Pour la méthode QR Farfield avec la distance 'ps norm', et un ensemble de validation à  $n = 23$  éléments. Le graphique à gauche montre les points qui ont pour abscisses une vraie valeur du  $C_x$  et d'ordonnée la prédiction associée. Si les points se situent entre les courbes vertes (respectivement rouges), l'erreur relative de prédiction est inférieure à 3% (respectivement à 5%). À droite on représente les points de coordonnées " $(|SC_x(A) - SC_x(B)|, |SC_{xpred}(A) - SC_{xpred}(B)|)$ " lorsque A et B représentent deux configurations différentes. Il y a donc  $\binom{n}{2} = \frac{n(n-1)}{2}$  points sur le graphique. Si les points se situent dans les enveloppes alors les prédictions sont satisfaisantes.

## 7 Conclusion

On a montré que pour déterminer le coefficient  $C_x$  il faut avoir accès à deux champs sur un plan à l'arrière du véhicule, soient un terme de vitesse projeté sur l'axe  $e_x$  et un terme de pression. Ces termes sont accessibles grâce aux résultats CDF de haute fidélité. Plusieurs axes sont étudiés pour déterminer la valeur du coefficient comme la réduction de dimension des données, dont le but de sélectionner les phénomènes les plus représentatifs de l'écoulement, pallier au phénomène du "fléau de la dimension" et exploiter au mieux le potentiel des prédictors. Cela est parfois fait pour réduire la taille des informations en entrée pour alléger les calculs. En utilisant une décomposition en valeur singulières ou des autoencodeurs simples, on a donc montré qu'il est possible de représenter les données temporelles des champs à l'arrière du véhicule dans un espace latent de dimension beaucoup plus petite. L'autre axe majeur est de développer des prédictors capables d'agréger des données relatives aux grandeurs des différents résultats CFD avec des données représentatives des géométries correspondantes afin de prédire les champs d'intérêt. On a montré que des méthodes sont à l'essai et permettent déjà d'obtenir des résultats prometteurs.

## Références

- [1] Philipe TRAORE & Sakir AMIROUDINE «Simulation numérique en mécanique des fluides»
- [2] Thomas ROUILLON « THÈSE DE DOCTORAT DE L'UNIVERSITÉ PIERRE ET MARIE CURIE »
- [3] Y. C. LIANG & H. P. LEE AND S. P. LIM & W. Z. LIN AND K. H. LEE & C. G. WU«PROPER ORTHOGONAL DECOMPOSITION AND ITS APPLICATIONS—PART I : THEORY»
- [4] Marion D'HONDT «Etude théorique, expérimentale et numérique de l'écoulement de refroidissement et de ses effets sur l'aérodynamique automobile»
- [5] Olivier BONNEFOY «Méthode de Boltzmann sur Réseau», Ecole Nationale Supérieure des Mines de Saint-Etienne.
- [6] Thomas Cavallazzi, papier sur le transport optimal discret